

**Un marco GeoAI reproducible para el análisis espaciotemporal explicable
de registros nacionales de personas desaparecidas: agrupamiento
multialgoritmo y validación multinivel (Perú, 2019–2025)**

*A reproducible GeoAI framework for explainable spatiotemporal analysis of national missing-person
registers: multi-algorithm clustering and multilevel validation (Peru, 2019–2025)*

Moisés Evangelista Gamarra^{a,*}, Edwar Abraham Alama Carreño^a, Pamela Estefani Figueroa
Rosas^a

^a Servicio Nacional de Adiestramiento en Trabajo Industrial (SENATI), Av. Alfredo Mendiola 3520,
Independencia, Lima 15311, Perú

* Autor de correspondencia: Moisés Evangelista Gamarra, mevangelistag@senati.pe

Correos: mevangelistag@senati.pe; 1634030@senati.pe; 1546935@senati.pe

ORCID: Moisés Evangelista Gamarra, <https://orcid.org/0009-0002-5382-1390>; Edwar Abraham Alama
Carreño, <https://orcid.org/0009-0006-8029-4302>; Pamela Estefani Figueroa Rosas,
<https://orcid.org/0009-0007-6100-9382>

16 **Resumen**

17 Los registros de denuncias por desaparición permiten describir patrones territoriales y
18 temporales, aunque su interpretación requiere distinguir el volumen registrado de su frecuencia
19 poblacional. Este estudio desarrolla y aplica un marco GeoAI reproducible a las 142 374
20 denuncias del Registro Nacional de Información de Personas Desaparecidas del Perú
21 (RENIPED, 2019–2025), organizadas en un panel de 26 territorios y 84 meses. El marco integra
22 tasas con denominadores oficiales, agrupamiento multialgoritmo, asociación espacial y
23 validación multinivel. Las tasas oscilaron entre 2,84 y 9,96 denuncias por cada 10 000 personas-
24 año; diez territorios, encabezados por Tacna, Apurímac, Huánuco, Cusco y Junín, presentaron
25 tasas mayores que el resto del país tras el control de falsos descubrimientos, y la clasificación
26 se mantuvo en dos análisis de sensibilidad. Lima Metropolitana concentró un tercio de las
27 denuncias, pero su tasa superó a la del resto en solo un 14 %. La autocorrelación espacial fue
28 significativa con cuatro vecinos más cercanos (I de Moran = 0,288; p = 0,018), pero no con
29 contigüidad; tras el ajuste de Benjamini–Hochberg se detectaron puntos fríos en el norte, pero
30 ningún punto caliente. El agrupamiento no mostró separación ni estabilidad suficientes para
31 respaldar categorías discretas, y cuatro estados resumen de forma descriptiva los perfiles
32 mensuales. El multiverso de especificaciones mostró que los grupos y el corredor de puntos
33 calientes de un análisis inicial dependían de decisiones analíticas concretas. El marco aporta
34 información complementaria para evaluar necesidades institucionales, sin estimar riesgo
35 individual ni establecer reglas de asignación de recursos.

36 **Palabras clave:** Personas desaparecidas; GeoAI; Agrupamiento espaciotemporal;
37 Autocorrelación espacial; Tasas de denuncias; Validación multinivel; Registros
38 administrativos

39 Aspectos destacados (highlights)

- 40 • Diez de 26 territorios tienen tasas de denuncias mayores que el resto del Perú
- 41 • Lima Metropolitana concentra un tercio de las denuncias, pero no la mayor tasa
- 42 • La evidencia de asociación espacial depende de la definición de vecindad
- 43 • Cuatro estados resumen perfiles mensuales sin demostrar categorías naturales
- 44 • El multiverso muestra la sensibilidad de los hallazgos a decisiones analíticas

45 1. Introducción

46 La desaparición de personas es un problema humanitario y de seguridad pública con
47 consecuencias profundas para las familias y las comunidades [1,2]. Como una de las pocas
48 fuentes sistemáticas sobre el fenómeno, los registros administrativos de denuncias constituyen
49 un recurso estratégico para orientar la búsqueda, la prevención y la asignación de recursos,
50 siempre que permitan responder a una pregunta concreta: cómo varía la tasa registrada de
51 denuncias entre territorios. En el Perú, el Registro Nacional de Información de Personas
52 Desaparecidas (RENIPED), a cargo de la Policía Nacional [3], acumuló 142 374 denuncias
53 entre 2019 y 2025, y su publicación como datos abiertos permite hoy abordar esa pregunta a
54 escala nacional [4], en un contexto en el que la Defensoría del Pueblo alerta periódicamente
55 sobre el número de denuncias por desaparición de mujeres [5].

56 Responder a esta pregunta exige distinguir el volumen de denuncias de su frecuencia en
57 relación con la población. Un territorio muy poblado puede acumular numerosos registros sin
58 presentar la tasa más elevada, mientras que otro de menor población puede registrar menos
59 denuncias y, al mismo tiempo, una tasa mayor. Lima Metropolitana ilustra bien esta tensión: al
60 concentrar un tercio de las denuncias del país, encabezaría cualquier ranking o mapa de conteos.
61 La inteligencia artificial geoespacial (GeoAI) ofrece herramientas adecuadas para este análisis,
62 desde el agrupamiento no supervisado de series territoriales hasta los indicadores de asociación

63 espacial que señalan puntos calientes y fríos [6–9], aunque su aplicación a registros de personas
64 desaparecidas es todavía incipiente [10,11].

65 Estas herramientas, sin embargo, obligan a tomar decisiones que pueden alterar el
66 resultado, como la unidad de análisis, las variables, el número de grupos, la matriz de vecindad
67 o el cálculo de los valores p. El problema de la unidad de área modificable ya mostró que las
68 decisiones de agregación bastan, por sí solas, para cambiar las conclusiones espaciales [12], y
69 cuando cada decisión se toma una única vez resulta difícil saber si un patrón refleja los datos o
70 el camino elegido para analizarlos [13,14]. Este riesgo es especialmente alto en registros
71 organizados como panel, que combinan pocos territorios con meses correlacionados entre sí.

72 La pregunta central de este estudio es cómo se distribuyen y evolucionan las tasas
73 registradas de denuncias por desaparición entre los territorios del Perú, qué perfiles mensuales
74 pueden describirse mediante el agrupamiento y qué evidencia de asociación espacial presentan.
75 Como dimensión complementaria, examinamos hasta qué punto la interpretación de estos
76 patrones se mantiene ante distintas decisiones analíticas. El objetivo general es desarrollar y
77 aplicar un marco GeoAI reproducible que integre la comparación de tasas, la caracterización de
78 estados espaciotemporales y el análisis de asociación espacial, con procedimientos de
79 validación que delimiten el alcance de sus resultados. Para alcanzarlo se plantean cinco
80 objetivos específicos:

- 81 • **(i)** estimar las tasas territoriales de denuncias y sus razones respecto del resto del país,
82 cuantificando su incertidumbre y examinando su persistencia anual;
- 83 • **(ii)** caracterizar perfiles mensuales mediante variables de comportamiento relativo y nivel
84 previo, y comparar las particiones obtenidas con distintos algoritmos de agrupamiento;
- 85 • **(iii)** evaluar la asociación espacial global y local de las tasas, considerando definiciones
86 alternativas de vecindad y el ajuste por comparaciones múltiples;

- (iv) examinar la transferencia temporal de los estados mediante su aplicación a años posteriores y la comparación con las particiones obtenidas en esos periodos, y
- (v) evaluar la estabilidad y la sensibilidad de los hallazgos frente al remuestreo, la asociación con la identidad territorial y un conjunto definido de especificaciones alternativas.

La contribución aplicada es una caracterización conjunta de las diferencias territoriales, los perfiles mensuales y la asociación espacial de las denuncias registradas en el Perú entre 2019 y 2025, que distingue cuánto se registra en cada territorio, con qué frecuencia en relación con su población, cómo se comporta un mes frente a su historia reciente y si los valores se asocian con los de los territorios vecinos. La contribución metodológica es una implementación integrada y documentada de métodos existentes que acompaña cada componente con comprobaciones de incertidumbre, estabilidad o sensibilidad; su aplicación a otros registros requiere validación adicional.

2. Trabajos relacionados

2.1. GeoAI y registros de personas desaparecidas

La GeoAI combina el aprendizaje automático con datos espaciales para describir y predecir fenómenos geográficos [6,15,16]. En seguridad ciudadana, un flujo de trabajo común agrega los registros en paneles de territorio y periodo, los agrupa con algoritmos basados en centroides y representa en mapas los estados resultantes. Los datos de personas desaparecidas se han incorporado a este campo solo recientemente: Ruiz Reyes et al. revisaron las técnicas estadísticas y de análisis de datos que apoyan la búsqueda de personas desaparecidas [10]; Escobar et al. publicaron un panel mensual por municipio de casos de desaparición y sus desenlaces en México [11], y Johnson et al. aplicaron agrupamiento espacial a registros de personas desaparecidas para ubicar acciones de difusión comunitaria [17]. Estos trabajos abren

los registros al análisis a gran escala, pero también lo exponen a sus propiedades: denuncias que no equivalen a personas, cobertura intermitente y pocas unidades territoriales.

2.2. Tasas y estructura espacial del riesgo

La comparación entre territorios de distinto tamaño descansa en tasas por habitante. Dado que las tasas calculadas sobre poblaciones pequeñas son más variables, el ajuste bayesiano empírico de Assunção y Reis corrige esta diferencia al medir la autocorrelación [18]. El índice I de Moran mide si los territorios vecinos tienden a presentar tasas parecidas [19]; los indicadores locales de asociación espacial (LISA) lo descomponen por territorio [7], y los estadísticos G de Getis–Ord identifican concentraciones de valores altos o bajos [8,9]. La inferencia de estos estadísticos locales se basa en la aleatorización condicional, que fija el valor del territorio evaluado y sortea sus vecinos entre los demás valores [7]. Con pocos territorios, esta distribución es discreta: un territorio con un solo vecino entre 26 admite 25 configuraciones posibles, de modo que su valor p bilateral no puede ser inferior a $2/25 = 0,08$. Además, como la prueba se repite en cada territorio, se requiere una corrección por comparaciones múltiples, como el control de la tasa de falsos descubrimientos (FDR) de Benjamini y Hochberg [20].

2.3. Agrupamiento y validación del número de grupos

Los índices internos, como el coeficiente de silueta [21], resumen el grado de separación entre grupos, pero no pueden indicar que los grupos no existan, porque no están definidos para un único grupo [22]. El estadístico gap, en cambio, compara la dispersión de los datos con la de datos de referencia sin estructura y admite un solo grupo como respuesta válida [23]. La validación por estabilidad complementa ambos criterios al evaluar si una partición reaparece cuando se perturban los datos [24,25], si bien su resultado depende del tipo de perturbación [26]. En los paneles, esta dependencia es decisiva: remuestrear filas trata como independientes

los meses de un mismo territorio, mientras que el remuestreo por bloques conserva la dependencia temporal [27].

2.4. Asociación entre los grupos y la identidad territorial

En el aprendizaje supervisado, la fuga de información ocurre cuando el desarrollo o la evaluación del modelo utiliza información que no debería estar disponible en las condiciones de aplicación previstas [28,29]. En el agrupamiento de registros territoriales surge una cuestión relacionada, aunque distinta: las variables que representan niveles habituales pueden producir grupos asociados principalmente con el territorio de procedencia, en lugar de distinguir situaciones temporales compartidas entre territorios. La información mutua normalizada permite cuantificar esta asociación [30], pero no establece por sí sola si se debe a diferencias territoriales reales o a las características de la representación utilizada.

2.5. Robustez frente a decisiones analíticas

Cuando muchos equipos analizan los mismos datos, sus conclusiones pueden diferir de forma considerable [14]. El análisis multiverso [31] y el análisis de curva de especificaciones [32] abordan este problema ejecutando todas las combinaciones razonables de decisiones y mostrando la distribución completa de resultados. Si bien estos métodos se han aplicado sobre todo a modelos de regresión, en este estudio se extienden al agrupamiento y a la estadística espacial local como parte de la validación.

3. Datos

3.1. El registro de personas desaparecidas

Las denuncias se registran en el Sistema de Denuncias Policiales (SIDPOL) de la Policía Nacional y las consolida la Dirección General de Información para la Seguridad del Ministerio del Interior (MININTER), que publica agregados mensuales en la Plataforma Nacional de

157 Datos Abiertos con licencia ODC-By [4]. Utilizamos el archivo de enero de 2019 a diciembre
158 de 2025, cuya integridad verificamos mediante su código SHA-256 (que empieza con
159 c41ebcce). El archivo contiene 77 331 filas, cada una de las cuales corresponde a una celda
160 definida por el distrito del hecho, el año, el mes, el grupo de edad, el sexo y la nacionalidad, y
161 registra un número de denuncias que, en conjunto, suman 142 374.

162 Tres propiedades del registro condicionan su interpretación. En primer lugar, la unidad de
163 registro es la denuncia y no la persona, de modo que quien es denunciado más de una vez se
164 cuenta más de una vez, un rasgo conocido de los datos policiales sobre personas desaparecidas
165 [33,34], y el registro no indica si la persona fue encontrada. En segundo lugar, 1 197 filas (1
166 357 denuncias) tienen la edad desconocida y 83 filas (90 denuncias) el sexo desconocido; todas
167 se conservaron sin imputar. Por último, el MININTER describe 2025 como un año preliminar
168 [35], por lo que 2024 es el último año consolidado. Los totales anuales oscilaron entre 18 192
169 denuncias en 2023 y 26 331 en 2019 (2020: 18 481; 2021: 20 141; 2022: 18 862; 2024: 19 420;
170 2025: 20 947).

171 **3.2. Territorios y población**

172 Puesto que el registro codifica el departamento del hecho y separa Lima Metropolitana del
173 resto del departamento de Lima, trabajamos con 26 territorios: 23 departamentos, la Provincia
174 Constitucional del Callao, Lima Metropolitana (provincia 150100) y Región Lima
175 (departamento 150000 menos la provincia 150100). La población procede de las proyecciones
176 del Instituto Nacional de Estadística e Informática (INEI) al 30 de junio de cada año [36], que
177 el propio INEI califica como preliminares. Entre 2019 y 2025, los 26 territorios sumaron 233
178 303 895 personas-año.

3.3. Vacíos de cobertura

Ocho combinaciones de departamento y mes carecen de filas en la fuente. Seis corresponden a enero de 2023 (Madre de Dios, Moquegua, Piura, Puno, San Martín y Tacna), un vacío coherente con la nota de la Defensoría del Pueblo según la cual la estadística policial al 13 de febrero de 2023 no incluía esos departamentos [37]; las dos restantes corresponden a Moquegua en mayo y junio de 2020, y su cobertura no pudo verificarse. Los ocho casos se trataron como datos faltantes y nunca como ceros, de modo que 2 176 de los 2 184 departamento-mes están observados.

En consecuencia, empleamos dos definiciones de la tasa. La principal divide las denuncias entre las personas-año de los meses observados (exposición observada), mientras que la de sensibilidad utiliza las personas-año de todos los meses (exposición total). Con la primera, la tasa nacional fue de 6,114 denuncias por cada 10 000 personas-año, y con la segunda, de 6,103.

La tasa expresa, por tanto, la frecuencia de denuncias registradas en relación con la población y el tiempo de observación de cada territorio. Como los datos agregados no identifican personas únicas ni el desenlace de cada denuncia, no estima la probabilidad individual de desaparición ni la proporción de personas que permanecen desaparecidas, y las diferencias territoriales pueden reflejar tanto la ocurrencia del fenómeno como su denuncia y registro, componentes que estos datos no permiten separar.

3.4. Panel, particiones temporales y geometría

El registro se estructuró en un panel de 26 territorios por 84 meses que conserva íntegramente las 142 374 denuncias de la fuente. Para el agrupamiento y su validación temporal definimos dos particiones: en la principal, los modelos se ajustan con 2019–2023 y se evalúan con los datos de 2024; en la secundaria, se ajustan con el periodo consolidado 2019–2024 y se evalúa su transferencia a 2025. Como el nivel previo (Sección 4.2) exige al menos seis meses observados entre los 12 anteriores, los primeros meses de cada serie no generan variables

204 completas; en consecuencia, la partición principal dispuso de 1 396 filas territorio-mes para el
205 ajuste y de 312 filas de 2024 para la evaluación.

206 Para el análisis espacial partimos de una capa simplificada de 197 provincias, derivada de
207 la cartografía censal del INEI y distribuida por un tercero [38]. Las provincias se agregaron en
208 los 26 territorios del panel y la capa resultante se proyectó a la zona UTM 18 Sur (EPSG:32718),
209 un sistema métrico adecuado para calcular distancias y relaciones de vecindad. Con contigüidad
210 de tipo reina, en la que dos territorios son vecinos si comparten un tramo o un punto de su
211 límite, cada territorio tuvo en promedio 4,15 vecinos (entre 1 y 7). Como sensibilidad
212 empleamos los cuatro vecinos más cercanos según la distancia sobre la superficie terrestre,
213 calculada con la fórmula de haversine.

214 **4. Marco analítico**

215 El marco se articula en cinco etapas que responden a los objetivos (i)–(v): tasas y territorios
216 prioritarios, estados espaciotemporales, estructura espacial, dinámica temporal y validación
217 multinivel (Fig. 1). Las cuatro primeras parten del mismo panel territorio-mes, y los resultados
218 de las etapas (ii)–(iv) se someten en la quinta a un conjunto de pruebas y curvas de
219 especificaciones, de modo que cada hallazgo se acompaña de una evaluación de su solidez
220 frente a alternativas razonables. Para limitar la flexibilidad analítica, todos los parámetros están
221 fijados en la versión 3.3.2 de un plan de análisis cuya huella SHA-256 se comprueba al iniciar
222 cada corrida, y el historial del plan documenta cada cambio y su motivo, incluida la
223 incorporación de la primera etapa después de revisar resultados intermedios.




Fig. 1. Arquitectura del marco GeoAI. Las tres fuentes se integran en un panel de 26 territorios por 84 meses, del que parten cuatro etapas de análisis: (i) territorios prioritarios, (ii) estados espaciotemporales, (iii) estructura espacial y (iv) dinámica temporal. La etapa (v) valida los resultados de las etapas (ii)–(iv) mediante la identidad territorial, la reproducción del análisis inicial y un multiverso de especificaciones. Las flechas en cursiva indican dónde se presenta cada resultado; la franja inferior resume las garantías de reproducibilidad.

4.1. Tasas y territorios prioritarios

Para cada territorio u calculamos la tasa de denuncias por cada 10 000 personas-año y la comparamos con la del resto del país, es decir, con la del conjunto de los otros 25 territorios, mediante la razón de tasas:

$$RR_u = \frac{tasa_u}{tasa_{resto(u)}} \quad (1)$$

Una razón de tasas de 1,5 indica que la tasa registrada en el territorio es un 50 % mayor que la del conjunto de los otros 25 territorios en el periodo analizado; se refiere a denuncias por unidad de población y tiempo, y no a una probabilidad individual de desaparición un 50 % mayor. Tomamos el resto del país como referencia para que las denuncias y la población del territorio evaluado no formen parte de ambos términos de la comparación, algo especialmente relevante en Lima Metropolitana, cuyo peso en el total nacional acercaría a la igualdad su comparación con el promedio nacional.

242 La incertidumbre de RR_u se estimó mediante un bootstrap de bloques móviles [27,39] con
243 9 999 réplicas. En cada réplica se seleccionaron con reemplazo bloques de 12 meses
244 consecutivos (siete para 2019–2025 y seis para 2019–2024), los mismos para los 26 territorios,
245 y con las denuncias y la exposición de esos meses se recalcularon la tasa de cada territorio, la
246 del resto del país y su razón. Cada bloque abarca un ciclo anual completo, y el remuestreo
247 conjunto conserva la correspondencia temporal entre territorios, aunque no necesariamente la
248 dependencia entre bloques. Los intervalos de confianza al 95 % corresponden a los percentiles
249 2,5 y 97,5 de las réplicas y son individuales, sin ajuste por las 26 comparaciones.

250 Para contrastar $RR_u = 1$ calculamos valores p bilaterales aproximados a partir de la
251 distribución bootstrap: duplicamos la menor de dos proporciones —las réplicas con una razón
252 ≤ 1 y las réplicas con una razón ≥ 1 —, cada una calculada como $(\text{conteo} + 1)/(9\,999 + 1)$, con
253 un máximo de 1. A continuación aplicamos el procedimiento de Benjamini y Hochberg a las
254 26 comparaciones [20]. Un territorio se clasificó como de tasa **mayor** o **menor** que el resto
255 cuando su valor p ajustado (valor q) fue inferior a 0,05, según el sentido de la razón estimada,
256 y como **no distinguible** en caso contrario, es decir, cuando no se detectó una diferencia
257 significativa. Como criterio complementario de persistencia contamos en cuántos de los siete
258 años su tasa anual superó a la del resto, y repetimos el análisis, como sensibilidad, con el periodo
259 consolidado 2019–2024 y con la exposición total.

260 *4.2. Variables y espacios de variables*

261 Para describir la evolución mensual de cada territorio construimos las variables de la Tabla
262 1. Sea $r_{u,t}$ la tasa mensual de denuncias del territorio u en el mes t , es decir, las denuncias
263 registradas divididas entre la población proyectada para ese año y multiplicadas por 10 000.
264 Para reducir la asimetría de su distribución utilizamos la **tasa mensual transformada** y:

$$265 \quad y_{u,t} = \ln(1 + r_{u,t}) \quad (2)$$

266 El **nivel previo** N resume la historia reciente como el promedio de y en los 12 meses
 267 anteriores, excluido el mes actual, con los meses observados y un mínimo de seis:

$$268 \quad N_{u,t} = \frac{1}{|M_{u,t}|} \sum_{i \in M_{u,t}} y_{u,t-i} \quad (3)$$

269 donde $M_{u,t} = \{i : 1 \leq i \leq 12 \text{ e } y_{u,t-i} \text{ observado}\}$ es el conjunto de meses previos con cobertura,
 270 y se exige $|M_{u,t}| \geq 6$. El **cambio frente al nivel previo** C es la diferencia entre y en el mes actual
 271 y ese nivel: un valor positivo sitúa el mes por encima de su historia reciente y uno negativo, por
 272 debajo, en la escala transformada y no como cambio porcentual:

$$273 \quad C_{u,t} = y_{u,t} - N_{u,t} \quad (4)$$

274 Por último, la **anomalía estacional** A compara cada mes con el promedio del mismo mes
 275 del año en el mismo territorio:

$$276 \quad A_{u,t} = \frac{y_{u,t} - \mu_{u,mes(t)}}{\sigma_u} \quad (5)$$

277 donde $\mu_{u,mes(t)}$ es la media de y en el mismo mes calendario y territorio (por ejemplo, todos
 278 los enero) y σ_u es la desviación estándar de los residuos respecto de esas medias estacionales,
 279 ambas estimadas solo con los años de entrenamiento para no utilizar información del futuro. A
 280 expresa, por tanto, cuánto se aparta un mes de su referencia estacional en unidades de la
 281 variabilidad residual del territorio; un valor alejado de cero no constituye por sí solo una
 282 anomalía estadísticamente significativa.

283 Con estas variables definimos tres espacios que difieren en la cantidad de nivel territorial
 284 que contienen: el **espacio relativo (E1)**, con A y C ; el **espacio mixto (E2)**, que es el principal
 285 y añade N , y el **espacio de nivel (E3)**, con y y N . Las variables de cada espacio se estandarizaron
 286 con la media y la desviación estándar del conjunto de entrenamiento, y esos mismos parámetros
 287 se aplicaron a las observaciones de evaluación. Este escalado es distinto de la normalización
 288 territorial de A , de modo que los perfiles estandarizados se interpretan respecto de la
 289 distribución de entrenamiento.

Tabla 1. Variables del análisis y espacios de variables. Los nombres internos del código se incluyen solo para facilitar la verificación del paquete de reproducibilidad.

Variable	Símbolo	Qué mide	Nombre en el código
Tasa mensual	r	Denuncias por 10 000 habitantes durante el mes	TASA_10K
Tasa mensual transformada	y	Logaritmo natural de $1 + r$	LOG_TASA
Nivel previo	N	Promedio de y en los 12 meses anteriores, con al menos seis meses observados	NIVEL_PREV12
Cambio frente al nivel previo	C	Diferencia entre y del mes actual y N	CAMBIO_12M
Anomalía estacional	A	Diferencia respecto de la media estacional de y , dividida entre la desviación estándar residual del territorio	ANOMALIA
Participación territorial en el registro	P	Proporción de denuncias (panel) o de filas (celdas) del territorio; solo en especificaciones de sensibilidad	DPTO_ID
Espacio		Variables incluidas	
Relativo (E1)		A, C	E1_relativo
Mixto (E2, principal)		A, C, N	E2_relativo_mas_nivel
De nivel (E3)		y, N	E3_nivel

4.3. Agrupamiento multialgoritmo

Agrupamos los meses de cada territorio con k-medias para $K = 2$ a 8 grupos, implementado en scikit-learn [40] (semilla 42; 10 inicializaciones durante la selección de K y 20 en las particiones finales). Para comprobar que los estados no dependían de un algoritmo concreto, ajustamos también un agrupamiento jerárquico de Ward, un modelo de mezcla gaussiana y HDBSCAN [41], y comparamos sus particiones con la de k-medias mediante el índice de Rand ajustado (ARI), que vale 1 cuando dos particiones coinciden y se aproxima a 0 cuando solo coinciden por azar [42]. Los grupos se numeraron por su tasa mensual media, de menor a mayor, de modo que el estado 0 es siempre el más bajo.

La evaluación distinguió entre la evidencia de separación en grupos y la selección de una partición para describir los datos. Para la primera calculamos el estadístico gap desde $K = 1$, con 100 muestras de referencia y la regla de un error estándar de Tibshirani [23]. Para la segunda evaluamos las particiones de $K = 2$ a 8 por su estabilidad, medida como el ARI medio en 100 remuestras de territorios completos y de bloques de 12 meses; el remuestreo de filas se

informa como comparación, pero no interviene en la selección. Fueron candidatos los K con un ARI medio de al menos 0,80 con ambos esquemas, umbral adoptado como criterio operativo, y entre ellos se elegía el K de la regla del gap aplicada desde $K = 2$ o, si no era candidato, el de mayor silueta. Si ningún K alcanzaba el umbral, una regla de respaldo elegía la partición con la mayor estabilidad mínima entre ambos esquemas (el menor K en caso de empate), una síntesis descriptiva que no constituye evidencia de grupos separados. Informamos, además, la silueta y los índices de Davies–Bouldin [43] y Calinski–Harabasz [44].

4.4. Estructura espacial

Medimos la autocorrelación global de las tasas de 2019–2025 con el I de Moran [19], con 9 999 permutaciones y valores p bilaterales. Para evaluar la robustez del patrón repetimos el cálculo (a) con el periodo consolidado 2019–2024, (b) con el ajuste bayesiano empírico, que estabiliza la varianza de las tasas en los territorios poco poblados [18], (c) con los conteos de denuncias y (d) con la proporción de meses que cada territorio pasó en el estado de mayor tasa. Un análisis «dejando uno fuera» recalculó, además, el índice tras retirar cada territorio. En el plano local calculamos el estadístico G_i^* de Getis–Ord [8,9] y el I de Moran local [7] con PySAL [45].

Para los análisis locales principales, con contigüidad y con cuatro vecinos más cercanos, obtuvimos los valores p mediante aleatorización condicional exacta. Con el valor del territorio evaluado y su número de vecinos fijos, enumeramos todas las combinaciones de valores que podían ocupar las posiciones vecinas entre los otros 25 territorios; con los pesos uniformes empleados, ambos estadísticos dependen solo de la suma de esos valores. El valor p bilateral duplica la menor de las proporciones de combinaciones con una suma mayor o igual, o menor o igual, que la observada, con un máximo de 1, y en ausencia de empates su valor mínimo alcanzable es:

$$p_{\min} = \frac{2}{C(25,k)} = \frac{2 \cdot k! \cdot (25-k)!}{25!} \quad (6)$$

donde $C(25, k)$ es el número de formas de elegir k vecinos entre 25. Para un territorio con un solo vecino, $p_{\min} = 2/25 = 0,08$, de modo que Callao y Tumbes no pueden alcanzar significación al 5 % con este contraste y la matriz de contigüidad; esta restricción refleja la resolución del procedimiento y no implica ausencia de asociación espacial. Cuando las combinaciones superaron el millón recurrimos a 99 999 sorteos con semilla fija. Controlamos la FDR entre los 26 territorios con el procedimiento de Benjamini y Hochberg, e informamos también los resultados sin corrección y, como sensibilidad, con el de Benjamini y Yekutieli, válido bajo cualquier forma de dependencia entre las pruebas [46]. La enumeración exacta elimina la variabilidad del sorteo, y la semilla fija permite reproducir los cálculos aproximados.

4.5. *Dinámica temporal*

La transferencia temporal se evaluó aplicando el modelo ajustado en el periodo de entrenamiento a las observaciones del año posterior. Sobre esas mismas observaciones reajustamos k-medias con el mismo número de estados y comparamos ambas asignaciones con el ARI. Como la partición reajustada es una referencia interna y no una clasificación verdadera, el ARI mide concordancia y no exactitud predictiva. Comparamos, además, la proporción de observaciones en cada estado entre el entrenamiento y el año de evaluación mediante la distancia de Jensen–Shannon en base 2 [47,48], que varía entre 0 y 1 y describe cambios en la distribución de los estados, pero no en las asignaciones individuales.

4.6. *Validación multinivel*

La última etapa evalúa si los patrones anteriores reflejan el fenómeno o dependen de las decisiones analíticas, y lo hace en tres niveles complementarios.

Asociación con la identidad territorial. Esta evaluación examina en qué medida los estados obtenidos están vinculados al territorio de procedencia de las observaciones. Para ello

355 calculamos la información mutua normalizada (NMI) entre los estados y los territorios [30] y
356 la fracción de incertidumbre sobre el estado que se reduce al conocer el territorio:

$$357 \quad U = 1 - \frac{H(G|T)}{H(G)} \quad (7)$$

358 donde $H(G | T)$ es la entropía de los estados condicionada al territorio y $H(G)$, la entropía
359 de la partición. Un valor de $U = 0,25$ indica que conocer el territorio reduce en una cuarta parte
360 la incertidumbre sobre el estado, sin implicar que el territorio cause la pertenencia. La NMI
361 observada se comparó con una distribución de referencia de 999 permutaciones que, en cada
362 año, reasignan al azar las identidades territoriales con una misma reasignación para todos los
363 meses de cada territorio, lo que conserva las secuencias dentro de cada año pero altera la
364 correspondencia territorial entre años. Denominamos **fuga de identidad** a la señal operativa
365 definida por $p < 0,05$ y $U \geq 0,25$; este umbral organiza la comparación entre especificaciones,
366 pero no es un criterio universal ni demuestra por sí solo una fuga de información.

367 **Reproducción del análisis inicial (línea base).** Para disponer de un punto de referencia
368 reprodujimos un análisis inicial de estos datos, realizado por los autores de forma convencional.
369 Ese análisis agrupó las celdas del registro en tres estados con nueve variables, escalado robusto
370 y la regla de silueta máxima, y señaló un corredor surandino de puntos calientes con cinco
371 vecinos más cercanos sobre centroides digitados a mano, valores p de una cola y ninguna
372 corrección por comparaciones múltiples.

373 **Multiverso.** Para examinar la sensibilidad de las conclusiones a las decisiones analíticas
374 evaluamos un conjunto definido de especificaciones [31,32], que no agota todas las decisiones
375 posibles. El multiverso de agrupamiento (M1) cruzó la unidad de análisis (panel o celda), el
376 recorte de valores extremos, el espacio de variables (E1, E2, E3, E2 más el peso del territorio
377 y, para celdas, las nueve variables iniciales), el escalado y la regla para elegir K , hasta sumar
378 108 especificaciones. Para que la ejecución fuera viable, M1 empleó un presupuesto reducido:
379 20 remuestras, cinco inicializaciones, K entre 2 y 6, 199 permutaciones para la distribución

nula, siluetas sobre 5 000 filas y, como el análisis inicial, una submuestra de 20 000 celdas. El multiverso espacial (M2) cruzó el recorte de extremos, el periodo, la variable (dos tasas o el conteo), cinco matrices de vecindad (incluidas las dos del análisis inicial), el tipo de valor p (de una o de dos colas) y la corrección por comparaciones múltiples, hasta sumar 240 especificaciones. En cada especificación evaluamos afirmaciones definidas en el plan, como «hay estructura según la silueta ($\geq 0,50$)», «hay fuga de identidad» o «hay un punto caliente surandino», y resumimos la asociación entre cada decisión y las métricas mediante el eta cuadrado parcial (η^2_p), que usamos solo para ordenar la importancia relativa de los factores dentro del diseño, no como efecto causal ni como porcentaje aditivo de la variación.

4.7. Reproducibilidad

El procedimiento se implementó en Python como un paquete organizado en módulos, acompañado de un cuaderno de Google Colab y de diez pruebas automáticas de sus componentes críticos. La versión analizada (3.3.2) fija todas las decisiones en un plan de análisis versionado, cuyo historial documenta cada modificación y su motivo. Todas las operaciones aleatorias usan la semilla 42, cada archivo de entrada se identifica por su código SHA-256 y cada resultado del análisis se lee de un único archivo de resultados, del que se generan también las figuras. La corrida de referencia en Google Colab (dos procesadores; Python 3.13, NumPy 2.1.3, scikit-learn 1.6.1 y esda 2.9.0) tardó 30 minutos. Una nueva ejecución completa en otro equipo, desde los mismos archivos de entrada y con las mismas versiones, reprodujo 34 de las 35 tablas con diferencias relativas inferiores a 10^{-10} ; la restante solo difirió en índices internos de HDBSCAN que el artículo no informa.

5. Resultados

5.1. Tasas y territorios prioritarios

La tasa de denuncias varió 3,5 veces entre territorios, desde 2,84 por cada 10 000 personas-año en Cajamarca hasta 9,96 en Tacna (Fig. 2). Diez territorios presentaron una tasa mayor que la del resto del país, ocho una tasa menor y ocho no se distinguieron del resto, una clasificación que se mantuvo exactamente igual en los dos análisis de sensibilidad, tanto con el periodo consolidado 2019–2024 como con la exposición total.

Cinco territorios del centro y del sur del país encabezaron la lista: Tacna ($RR = 1,64$; IC 95 %: 1,27–1,96), Apurímac (1,58; 1,51–1,76), Huánuco (1,51; 1,42–1,65), Cusco (1,49; 1,40–1,58) y Junín (1,43; 1,31–1,52). En todos ellos, la tasa anual superó a la del resto del país en cada uno de los siete años del estudio (Fig. 3). A continuación, se situaron Ayacucho (1,32; 1,09–1,59; cinco de siete años), Lambayeque (1,26) y Arequipa (1,20), estos dos últimos también por encima del resto en los siete años, seguidos de Lima Metropolitana (1,14) y Callao (1,06).

Lima Metropolitana ilustra con claridad la diferencia entre volumen e intensidad. Aunque fue el primer territorio en número de denuncias (46 848, el 33 % del país), ocupó el noveno lugar por tasa (6,70), y su exceso sobre el resto del país, de un 14 % ($RR = 1,14$; IC 95 %: 1,05–1,19), se repitió en seis de los siete años. Se trata, por tanto, de un exceso moderado y persistente, muy alejado de lo que sugeriría su volumen. Callao, con una tasa de 6,48, mostró un exceso aún menor (6 %).

En el extremo opuesto, los ocho territorios con tasas menores fueron Cajamarca ($RR = 0,45$), La Libertad (0,59), Piura (0,61), Loreto (0,61), San Martín (0,68), Áncash (0,73), Ica (0,77) y Amazonas (0,80), ninguno de los cuales superó al resto del país en año alguno, y seis de ellos (Amazonas, Cajamarca, La Libertad, Loreto, Piura y San Martín) se localizan en el norte. Entre los territorios no distinguibles coexisten algunos con intervalos amplios por su

menor población, como Madre de Dios (1,10; 0,75–1,26) y Pasco (0,99; 0,84–1,24), con otros cuyas tasas se aproximan a la del resto, como Moquegua (0,94) y Puno (0,86).





Fig. 2. Territorios prioritarios según la tasa de denuncias por desaparición, 2019–2025. (a) Clasificación de los 26 territorios: tasa mayor, menor o no distinguible de la del resto del país (control de la tasa de falsos descubrimientos al 5 %); los números identifican cada territorio según su posición en (b), y el recuadro amplía Lima Metropolitana (9), Callao (12) y Región Lima (15). (b) Razón de tasas de cada territorio frente al resto del país, con su intervalo de confianza al 95 % (bootstrap de bloques de 12 meses, 9 999 réplicas); a la derecha, el porcentaje de las denuncias nacionales que aporta cada territorio. Las líneas del mapa delimitan áreas de estudio y no representan necesariamente límites nacionales aceptados.

La Fig. 3 descompone esta clasificación año a año y permite distinguir un exceso persistente de uno concentrado en pocos años. Apurímac, Huánuco, Cusco y Junín se mantuvieron entre 1,19 y 1,79 en todos los años, y el exceso de Cusco creció de 1,29 en 2021 a 1,67 en 2025. En Tacna, por el contrario, el exceso se redujo de forma continua desde 2,48 en 2019 hasta 1,01 en 2024 y repuntó levemente en 2025 (1,17), de modo que su primer puesto obedece sobre todo a los primeros años del periodo. Ayacucho superó al resto hasta 2023, pero

442 quedó por debajo en 2024 (0,94) y 2025 (0,73). Los territorios de tasa menor, en cambio, lo
 443 fueron de forma sostenida, como Cajamarca, que no superó 0,54 en ningún año, mientras que
 444 entre los no distinguibles Madre de Dios osciló entre 0,45 y 1,65, lo que explica la amplitud de
 445 su intervalo. Conviene subrayar que estas razones anuales son descriptivas y carecen de
 446 intervalo de confianza; la clasificación se basa en el periodo completo.



447
 448 **Fig. 3.** Persistencia de la razón de tasas, 2019–2025. Cada celda muestra la razón entre la tasa del territorio en ese
 449 año y la del resto del país (exposición observada); los valores mayores que 1 (naranja) indican una tasa mayor, y
 450 los menores que 1 (azul), una tasa menor. La escala de color es logarítmica, de modo que 0,5 y 2 equidistan de 1.
 451 A la derecha se muestran la clasificación del periodo completo (Fig. 2) y el número de años en que la tasa superó
 452 a la del resto del país. Los territorios se ordenan por su razón de tasas del periodo completo, y 2025 es preliminar
 453 según la fuente.

454 5.2. Estados espaciotemporales

455 En el espacio mixto E2, los diagnósticos no ofrecieron evidencia consistente de grupos
 456 claramente separados y estables (Fig. 4a–c). El estadístico gap favoreció $K = 1$, con un valor de

457 1,851 frente a 1,380–1,432 para $K = 2-8$; la silueta se mantuvo entre 0,28 y 0,29, y ninguna
458 partición alcanzó un ARI medio de 0,80 con ambos esquemas de remuestreo. Por ello se aplicó
459 la regla de respaldo, que seleccionó $K = 4$ por presentar la mayor estabilidad mínima (0,63).
460 Los cuatro estados se utilizan, en consecuencia, para resumir perfiles mensuales de las variables
461 analizadas, sin interpretarlos como categorías naturales del fenómeno. La concordancia con
462 otros algoritmos también fue limitada: el ARI respecto de k-medias fue de 0,31 para Ward y de
463 0,23 para la mezcla gaussiana, mientras que HDBSCAN clasificó el 70 % de las observaciones
464 como ruido.

465 El perfil de los cuatro estados revela que combinan dos tipos de diferencia (Fig. 4d). Dos
466 de ellos describen la dinámica del mes y aparecen en los 26 territorios: el estado 0 reúne 163
467 meses muy por debajo de lo habitual, con una anomalía estacional media de $-1,40$ desviaciones
468 estándar residuales del territorio ($DE = 0,64$) y una tasa mensual media de 0,31 por cada 10 000
469 habitantes ($DE = 0,16$), y el estado 3 reúne 294 meses por encima de lo habitual, con una
470 anomalía de $+1,21$ ($DE = 0,55$) y una tasa de 0,78 ($DE = 0,29$). Los otros dos agrupan meses
471 de anomalía cercana a cero ($-0,38$ y $-0,11$) y se distinguen sobre todo por el nivel del territorio:
472 el estado 1 (500 meses de 19 territorios) corresponde a territorios de nivel previo bajo, con una
473 mediana estandarizada de $-1,00$, y el estado 2 (439 meses de 20 territorios), a territorios de
474 nivel alto, con una mediana de 0,59. Esta composición explica por qué, como se muestra en la
475 Sección 5.5, los estados comparten información con la identidad territorial.




Fig. 4. Elección del número de grupos y perfil de los estados en el espacio mixto (E2), 2019–2023 (n = 1 396 meses-territorio). (a) Estadístico gap con su error estándar; el diagnóstico favorece $K = 1$ y no respalda una separación en varios grupos en la representación evaluada. (b) Estabilidad media (ARI) en 100 remuestras según el esquema de remuestreo; la línea discontinua marca el umbral de 0,80 y la punteada vertical, el K elegido por la regla de respaldo. (c) Índice de silueta; la línea discontinua marca el valor de referencia de silueta adoptado en el análisis (0,50). (d) Distribución de las tres variables estandarizadas en cada uno de los cuatro estados ($K = 4$); la leyenda indica el número de meses, los territorios presentes y la tasa mensual media de cada estado.

5.3. Estructura espacial

La evidencia de autocorrelación espacial global de las tasas dependió de la definición de vecindad (Tabla 2). Con los cuatro vecinos más cercanos, el I de Moran fue de 0,288 ($p = 0,018$) para 2019–2025 y de 0,245 ($p = 0,032$) para el periodo consolidado 2019–2024, mientras que con contigüidad fue de 0,122 y no significativo ($p = 0,244$); el ajuste bayesiano empírico no modificó estos valores. Estos resultados respaldan una asociación positiva bajo la proximidad por vecinos cercanos, pero no una conclusión independiente de la matriz espacial. Los conteos y la proporción de meses en el estado de mayor tasa no mostraron autocorrelación significativa con ninguna de las dos matrices, y al retirar sucesivamente cada territorio (24 de las 26

exclusiones son calculables) el I de Moran con contigüidad varió entre 0,029 y 0,289 y solo fue significativo al excluir Huánuco, lo que muestra su sensibilidad a la composición territorial.

En el análisis local con G_i^* se identificaron puntos fríos tras el ajuste de Benjamini–Hochberg en Amazonas y Lambayeque con contigüidad, y en Lambayeque y San Martín con cuatro vecinos; con el ajuste más conservador de Benjamini–Yekutieli, solo Amazonas mantuvo la significación ($q = 0,032$). Ningún territorio fue punto caliente tras el ajuste con las dos matrices principales. Con contigüidad, Apurímac, Cusco y Ayacucho presentaron los valores positivos más altos de G_i^* (z entre 2,13 y 2,43), pero sus valores p bilaterales (0,057–0,064) no alcanzaron significación ni siquiera antes del ajuste. Lima Metropolitana tampoco mostró una concentración local significativa (con contigüidad, $z = 0,07$ y $p = 0,97$).

La clasificación local es distinta de la comparación de cada territorio con el resto del país. Lambayeque presenta una tasa superior a la del resto (Sección 5.1) y, a la vez, un entorno de valores bajos que G_i^* identifica como punto frío, mientras que el I de Moran local lo caracteriza como un territorio de valor alto rodeado de valores bajos; ambas lecturas describen aspectos distintos de su posición espacial.

Tabla 2. Estructura espacial de las denuncias por desaparición. Panel A: I de Moran global (9 999 permutaciones; valor p bilateral). Panel B: territorios significativos tras el control de la tasa de falsos descubrimientos (valores p locales exactos; tasa 2019–2025 con exposición observada).

Panel A. Variable y periodo	I (contigüidad)	p	I (4 vecinos)	p
Tasa, exposición observada, 2019–2025	0,122	0,244	0,288	0,018
Tasa, exposición total, 2019–2025	0,116	0,260	0,282	0,020
Tasa bayesiana empírica, 2019–2025	0,122	0,244	0,288	0,018
Tasa, exposición observada, 2019–2024	0,094	0,325	0,245	0,032
Conteo de denuncias, 2019–2025	–0,008	0,537	–0,004	0,451
Proporción de meses en el estado alto, 2019–2023	–0,104	0,663	0,014	0,589
Panel B. Territorio (matriz)	G_i^* z	p exacto	q (FDR)	Tipo LISA
Amazonas (contigüidad)	–3,01	0,0003	0,008	Bajo-bajo
Lambayeque (contigüidad)	–1,95	0,002	0,023	Alto-bajo
Lambayeque (4 vecinos)	–2,12	0,002	0,037	Alto-bajo
San Martín (4 vecinos)	–2,84	0,003	0,037	Bajo-bajo

I: índice de Moran global (valor esperado sin autocorrelación: –0,04). G_i^* z: valor estandarizado del estadístico de Getis–Ord; los valores negativos indican concentración de valores bajos (punto frío). q: valor p ajustado por Benjamini–Hochberg; con el ajuste de Benjamini–Yekutieli solo Amazonas (contigüidad) mantiene $q < 0,05$ ($q = 0,032$). Tipo LISA: territorio (alto o bajo) frente a sus vecinos (alto o bajo). Ningún territorio fue punto caliente tras la corrección.

5.4. *Dinámica temporal*

En 2024, la partición transferida desde el ajuste de 2019–2023 presentó un ARI de 0,41 respecto de la partición reajustada en ese año; la proporción de observaciones en el estado 1 aumentó del 35,8 % durante el entrenamiento al 56,4 %, y la distancia de Jensen–Shannon entre las distribuciones de estados fue de 0,18. En 2025, con el modelo ajustado hasta 2024, el ARI fue de 0,52 y la distancia de 0,05, de modo que las proporciones se acercaron a las del entrenamiento, aunque persistieron diferencias entre las asignaciones transferidas y las reajustadas. Estos resultados describen una concordancia temporal parcial y no permiten interpretar los estados como categorías invariantes entre periodos.

5.5. *Validación multinivel*

Asociación con la identidad territorial. La información compartida entre los estados y los territorios creció a medida que las variables incorporaban nivel territorial (Tabla 3, panel A). En el espacio relativo (E1), la NMI fue de 0,015 y no superó lo esperable por azar ($p = 0,81$); en el espacio mixto (E2) ascendió a 0,138 ($p = 0,001$), con un 24 % de la entropía de los grupos explicado por el territorio, justo por debajo del umbral de 0,25; y en el espacio de nivel (E3) llegó a 0,252, con un 45 % de la entropía explicado y tres territorios cuyos meses cayeron casi siempre en el mismo grupo. Exigir 12 meses de historia en lugar de 6 mantuvo el mismo orden entre espacios (NMI de 0,026, 0,166 y 0,271), si bien con esa exigencia E2 superó el umbral de fuga (fracción de 0,29).

Reproducción del análisis inicial. El marco reprodujo el análisis inicial: con celdas del registro, nueve variables, escalado robusto y la regla de silueta máxima eligió tres grupos con una silueta de 0,559 (0,550 en el informe inicial), y con su matriz de vecindad obtuvo un I de Moran de 0,330 y seis puntos calientes (Arequipa, Ayacucho, Cusco, Moquegua, Puno y Tacna). Esa partición, sin embargo, compartió mucha información con el territorio (NMI de 0,330; en 12 de los 26 territorios, al menos el 95 % de las celdas cayó en un mismo grupo), y

con escalado estándar la misma especificación eligió dos grupos, y cada territorio cayó íntegro en uno de ellos. Los tres grupos iniciales describían, así, sobre todo diferencias de tamaño e identidad territorial.

Multiverso. En las 108 especificaciones de agrupamiento, el remuestreo de filas indicó estabilidad en el 97 % de los casos, frente a solo el 31 % cuando se remuestrearon territorios y bloques; la silueta superó 0,50 en el 34 % y el 62 % mostró fuga de identidad según el criterio operativo de la Sección 4.6 (Tabla 3, panel B; Fig. 5a). Dentro del conjunto evaluado, el espacio de variables fue la decisión más asociada con las diferencias de NMI ($\eta^2_p = 0,60$), y el escalado y la unidad de análisis, las más asociadas con las de silueta ($\eta^2_p = 0,37$ en ambos casos).

En las 160 especificaciones espaciales de tasas, el I de Moran fue significativo en el 72,5 % (en el 65 % con valores p bilaterales), nunca con contigüidad y, con valores p bilaterales, en el 50–100 % de las especificaciones con las otras cuatro matrices (Fig. 5b). El punto caliente surandino apareció en todas las especificaciones con valores p de una cola sin corrección, pero en ninguna con valores p bilaterales y control de la FDR. En este último escenario, solo la matriz de distancia inversa del análisis inicial señaló puntos calientes (8 de 40 especificaciones: Apurímac, Madre de Dios y Puno), con valores p locales obtenidos por sorteo porque esa matriz asigna a cada territorio entre 6 y 18 vecinos. Lima Metropolitana no fue punto caliente en ninguna de las 240 especificaciones espaciales.

La Fig. 5 resume ambas validaciones mediante curvas de especificaciones. Cada punto representa una especificación, ordenada según el valor de la métrica, y las marcas inferiores identifican las opciones utilizadas; su concentración en un sector de la curva señala una asociación entre la decisión y el resultado, sin aislar por sí sola su efecto. En el panel (a), 39 de las 41 especificaciones sin fuga de identidad utilizan variables relativas (E1) o mixtas (E2), y ninguna emplea solo variables de nivel (E3) ni las nueve variables del análisis inicial, cuyas especificaciones se sitúan entre las de mayor NMI (0,26–0,33). En el panel (b), la contigüidad


ocupa las ocho posiciones más bajas sin ninguna especificación significativa, mientras que la matriz de cinco vecinos del análisis inicial se sitúa en el extremo superior.

Tabla 3. Validación multinivel. Panel A: información compartida entre los estados y los territorios según el espacio de variables (2019–2023, $K = 4$; 999 permutaciones por años). Panel B: proporción de especificaciones del multiverso que respaldan cada afirmación.

Panel A. Espacio de variables	NMI	Umbral nulo (p95)	Valor p	Fracción de entropía
Relativo (E1)	0,015	0,021	0,813	0,027
Mixto (E2)	0,138	0,065	0,001	0,240
De nivel (E3)	0,252	0,116	0,001	0,453
Panel B. Afirmación	Especificaciones	Respaldo		
Estructura según la silueta ($\geq 0,50$)	108	34,3 %		
Estructura estable al remuestrear filas	108	97,2 %		
Estructura estable al remuestrear territorios y bloques	108	30,6 %		
Fuga de identidad territorial	108	62,0 %		
Autocorrelación global de las tasas	160	72,5 %		
Punto caliente surandino (p de una cola, sin corrección)	40	100 %		
Punto caliente surandino (p bilateral y FDR)	40	0 %		
Punto caliente en Lima Metropolitana	240	0 %		

NMI: información mutua normalizada entre el grupo y el territorio. Fracción de entropía: parte de la incertidumbre sobre el grupo que se elimina al conocer el territorio. Punto caliente surandino: al menos uno de los cinco territorios del corredor descrito en el informe inicial (Arequipa, Ayacucho, Cusco, Moquegua y Tacna), según la definición del plan; Puno, sexto punto caliente de la reproducción, se informa por separado. Con valores p bilaterales y FDR, 8 de las 40 especificaciones señalaron otros puntos calientes (Apurímac, Madre de Dios y Puno), todas con la matriz de distancia inversa del análisis inicial. Los porcentajes expresan la proporción de especificaciones evaluadas que cumplen cada criterio; no son probabilidades de que una afirmación sea verdadera ni proceden de réplicas independientes, pues las especificaciones comparten datos y decisiones analíticas.

(a) Agrupamiento: información compartida con el territorio (108 especificaciones)



(b) Estructura espacial: I de Moran global de las tasas (40 especificaciones)




Fig. 5. Validación multinivel mediante curvas de especificaciones. (a) Información mutua normalizada (NMI) entre el grupo y el territorio en las 108 especificaciones de agrupamiento; en naranja, las especificaciones con fuga de identidad territorial ($p < 0,05$ y fracción de entropía $\geq 0,25$). (b) I de Moran global de las tasas en 40 combinaciones de datos y matriz de vecindad (valores p bilaterales); en naranja, las significativas al 5 %. En ambos paneles, el círculo marca la especificación del análisis inicial y las filas inferiores indican las decisiones que definen cada especificación. Solo se muestran las decisiones más influyentes, ya que las omitidas influyen poco: en (a), la regla de elección de K ($\eta^2_p = 0,10$) y la winsorización ($\eta^2_p < 0,01$); en (b), la definición de la exposición y la winsorización, que cambian el I de Moran medio en menos de 0,01.

6. Discusión

6.1. Diferencias territoriales en las tasas de denuncias e implicaciones para la búsqueda

El resultado de mayor alcance para la política pública es la clasificación de la Fig. 2. Diez territorios presentan tasas de denuncias mayores que el resto del país tras el control de la FDR,

590 y cinco de ellos (Tacna, Apurímac, Huánuco, Cusco y Junín) las superan entre un 43 % y un 64
591 % en el periodo completo, con una tasa anual superior a la del resto en cada uno de los siete
592 años. La coincidencia de esta clasificación en los dos análisis de sensibilidad respalda su
593 consistencia frente a las variaciones de periodo y exposición examinadas. Estos resultados
594 pueden aportar un criterio complementario para evaluar necesidades de búsqueda, prevención
595 y revisión del registro, siempre que se interpreten junto con el volumen de denuncias, la
596 situación de los casos y la capacidad de respuesta institucional; por sí solos, no establecen una
597 regla de asignación de recursos. La Fig. 3 añade un matiz útil para la planificación: el exceso
598 de Apurímac, Huánuco, Cusco y Junín es estable, el de Cusco va en aumento y el de Tacna se
599 redujo hasta igualar al resto del país en 2024 (1,01) y repuntó apenas en 2025. Por ello, conviene
600 actualizar la clasificación cada año en lugar de fijar las prioridades solo con el promedio del
601 periodo.

602 Lima Metropolitana ilustra la utilidad de considerar conjuntamente el volumen y la tasa de
603 denuncias: el conteo describe la magnitud de la actividad registrada, mientras que la tasa sitúa
604 ese volumen en relación con su población y permite compararlo con otros territorios. Una
605 evaluación institucional de prioridades debería integrar ambas dimensiones con información
606 sobre los casos pendientes, su urgencia y los recursos disponibles, aspectos que exceden el
607 alcance de este estudio.

608 Las tasas bajas del norte, por su parte, deben interpretarse con prudencia, ya que una tasa
609 baja de denuncias puede reflejar menos desapariciones, pero también un menor acceso a las
610 comisarías, una menor disposición a denunciar o diferencias en el registro. Con los datos
611 disponibles no es posible discriminar entre estas explicaciones, por lo que no atribuimos causas
612 a los patrones observados. La misma cautela se aplica a las tasas altas, que indican dónde se
613 denuncia más por habitante, pero no por qué.

6.2. *Patrón espacial y estados del fenómeno*

La distribución observada muestra territorios de tasas elevadas en el centro y el sur del país, pero su interpretación como concentración espacial exige distinguir la descripción geográfica de la evidencia inferencial. La autocorrelación global fue significativa con cuatro vecinos más cercanos y no con contigüidad, y ningún punto caliente superó el ajuste por comparaciones múltiples con las matrices principales, de modo que los resultados no confirman un corredor de puntos calientes bajo estas especificaciones. Tampoco permiten atribuir esa ausencia solo a una potencia insuficiente, pues no evaluamos la potencia, aunque el valor p mínimo alcanzable limita la resolución de la prueba en los territorios con pocos vecinos. En el norte se detectaron puntos fríos con el ajuste de Benjamini–Hochberg, pero su localización dependió de la matriz y solo Amazonas conservó la significación con el de Benjamini–Yekutieli, por lo que la evidencia local debe leerse según la vecindad y el ajuste utilizados.

Los cuatro estados cumplen una función descriptiva: resumen combinaciones de anomalía estacional, cambio frente al nivel previo y nivel habitual, y distinguen meses relativamente bajos o altos de situaciones ligadas a diferencias persistentes entre territorios. La separación limitada y la sensibilidad de las particiones aconsejan, sin embargo, interpretar sus fronteras como aproximaciones analíticas y no como divisiones inherentes al fenómeno. La clasificación por tasas y el agrupamiento responden, además, a preguntas diferentes: la primera compara la frecuencia registrada durante un periodo y el segundo resume perfiles mensuales multivariados, por lo que la consistencia de la primera en dos análisis de sensibilidad no demuestra, por sí sola, una superioridad general frente al segundo.

6.3. *Qué aporta la validación multinivel*

La validación multinivel ayuda a interpretar las diferencias entre el análisis inicial y las especificaciones alternativas. Los grupos iniciales mostraron mayor separación y estabilidad bajo determinadas elecciones de unidad de análisis, variables y remuestreo, y su asociación con

la identidad territorial indicó que parte de esa organización estaba vinculada a diferencias persistentes entre territorios. Este resultado no demuestra por sí solo una fuga de información, pero limita la interpretación de los grupos como estados temporales compartidos. Asimismo, la identificación del corredor surandino cambió al modificar la lateralidad del contraste y el ajuste por comparaciones múltiples. En conjunto, estos resultados muestran la necesidad de evaluar qué conclusiones se mantienen frente a decisiones analíticas alternativas.

A partir de esta experiencia, recomendamos cinco comprobaciones para análisis similares: comparar tasas y no conteos, siempre con su incertidumbre; evaluar el estadístico gap desde un solo grupo; medir la estabilidad remuestreando territorios y bloques de tiempo; calcular valores p locales exactos e informar el mínimo alcanzable de cada territorio, y controlar la FDR con más de una matriz de vecindad.

6.4. *Limitaciones*

El estudio está condicionado por la naturaleza del registro administrativo. Las denuncias agregadas no identifican personas únicas ni el desenlace de los casos, por lo que las tasas describen la frecuencia registrada y no la probabilidad individual de desaparición, y las diferencias territoriales pueden reflejar tanto el fenómeno como el acceso a la denuncia y los procedimientos de registro. Las proyecciones poblacionales y los registros de 2025 son preliminares, y el tratamiento de los ocho territorio-mes sin información ajusta la exposición, pero no recupera las denuncias que pudieran faltar. La agregación en 26 territorios impide, además, trasladar los resultados a localidades o personas concretas.

En el plano metodológico, los hallazgos espaciales dependen de la definición de vecindad y del ajuste por comparaciones múltiples, y la capa geográfica procede de un tercero, por lo que su correspondencia con la cartografía oficial debe comprobarse antes de asumir que la contigüidad no cambia. Los intervalos de las razones de tasas se basan en bloques de longitud fija sobre siete años, pueden verse afectados por cambios de nivel o de tendencia y no

664 incorporan la incertidumbre del subregistro ni de las proyecciones. Los estados dependen de la
665 representación de las variables, y su asociación con la identidad territorial, evaluada con un
666 esquema específico de permutación anual, no separa por sí sola las diferencias persistentes del
667 registro de los efectos de esa representación; la evaluación temporal, limitada a dos años y sin
668 una clasificación verdadera de referencia, no mide exactitud predictiva.

669 Por último, el marco se evaluó en un solo registro y sin datos sintéticos de estructura
670 conocida, y el multiverso abarca un conjunto finito de decisiones con un presupuesto
671 computacional reducido. La comparación territorial de tasas se incorporó al plan después de
672 revisar resultados intermedios, como documenta su historial, lo que confiere a ese componente
673 un carácter exploratorio. Aplicar el procedimiento en otros contextos exigirá comprobar de
674 nuevo la cobertura, las unidades de análisis y los supuestos de cada método.

675 **6.5. Trabajo futuro**

676 Las extensiones del estudio pueden desarrollarse en tres direcciones: evaluar una escala
677 territorial más detallada, previa comprobación de la cobertura, de los denominadores y de la
678 estabilidad de las tasas en áreas pequeñas; aplicar el procedimiento a otros registros
679 administrativos para examinar qué componentes se mantienen y cuáles requieren adaptación, y
680 realizar experimentos con datos sintéticos que representen dependencia temporal, diferencias
681 territoriales persistentes, vacíos de cobertura y concentraciones espaciales conocidas, con el fin
682 de evaluar la calibración de los contrastes y la capacidad del marco para distinguir patrones
683 conocidos de variaciones introducidas por las decisiones analíticas.

684 **7. Conclusiones**

685 El estudio integró tasas poblacionales, agrupamiento y análisis espacial para caracterizar
686 las 142 374 denuncias por desaparición registradas en el Perú entre 2019 y 2025. Las tasas
687 variaron entre 2,84 y 9,96 denuncias por cada 10 000 personas-año, y diez territorios,

688 encabezados por Tacna, Apurímac, Huánuco, Cusco y Junín, presentaron tasas mayores que el
689 resto del país, con una clasificación que se mantuvo en los dos análisis de sensibilidad. Lima
690 Metropolitana concentró un tercio de las denuncias sin presentar la mayor tasa, lo que muestra
691 la utilidad de considerar conjuntamente el volumen registrado y su relación con la población.

692 La evidencia espacial dependió de la definición de vecindad: la autocorrelación global fue
693 significativa con cuatro vecinos más cercanos, pero no con contigüidad, y con las matrices
694 principales se identificaron puntos fríos tras el ajuste de Benjamini–Hochberg, pero ningún
695 punto caliente. En el agrupamiento, los diagnósticos no respaldaron grupos claramente
696 separados y estables en la representación evaluada; los cuatro estados seleccionados resumen
697 perfiles mensuales, aunque su interpretación debe considerar la asociación territorial y la
698 concordancia parcial entre periodos.

699 La contribución del marco consiste en articular estas perspectivas y acompañarlas de
700 comprobaciones que delimitan la interpretación de los resultados. Los hallazgos pueden aportar
701 información complementaria para evaluar necesidades institucionales, junto con la situación de
702 los casos y la capacidad de respuesta disponible, pero no establecen por sí solos una regla de
703 asignación de recursos ni una estimación del riesgo individual. El código, el plan de análisis y
704 los resultados se publican para facilitar su verificación; su extensión a otros registros requiere
705 validar las condiciones de aplicación y el comportamiento de los procedimientos utilizados.

706 **Disponibilidad de datos y código**

707 Los datos de denuncias proceden de la Plataforma Nacional de Datos Abiertos del Perú [4],
708 los denominadores poblacionales de las proyecciones del INEI [36] y la capa geográfica del
709 repositorio peru-geojson [38]; los tres archivos se identifican por su código SHA-256. Estos
710 archivos, el código, el plan de análisis, las pruebas automáticas, el cuaderno de Google Colab

711 y los resultados derivados de la versión 3.3.2 están disponibles en GitHub y archivados en
712 Zenodo [49].

713 **Referencias**

- 714 [1] International Commission on Missing Persons (ICMP), Annual Report 2024, The
715 Hague, 2025. [https://icmp.int/wp-content/uploads/2025/06/250415_ICMP_ANNUAL-](https://icmp.int/wp-content/uploads/2025/06/250415_ICMP_ANNUAL-REPORT-2024_DIGTAL_DEF-5.pdf)
716 [REPORT-2024_DIGTAL_DEF-5.pdf](https://icmp.int/wp-content/uploads/2025/06/250415_ICMP_ANNUAL-REPORT-2024_DIGTAL_DEF-5.pdf)
- 717 [2] International Committee of the Red Cross (ICRC), ICRC Strategy 2024–2027, Geneva,
718 2023. <https://www.icrc.org/en/publication/4745-icrc-strategy-2024-2027>
- 719 [3] Policía Nacional del Perú, Registro Nacional de Información de Personas Desaparecidas
720 (RENIPED). <https://desaparecidosenperu.policia.gob.pe/Desaparecidos/reniped>
721 (consultado el 26 de septiembre de 2026).
- 722 [4] [dataset] Ministerio del Interior (MININTER), Dirección General de Información para
723 la Seguridad, DataSet Personas desaparecidas – Enero 2019 a Diciembre 2025
724 (conjunto «Denuncias por desaparición de personas [MININTER]»), Plataforma
725 Nacional de Datos Abiertos, 2026. [https://www.datosabiertos.gob.pe/dataset/personas-](https://www.datosabiertos.gob.pe/dataset/personas-desaparecidas/resource/f49ae77f-8822-45ea-aa16-911d677e303d)
726 [desaparecidas/resource/f49ae77f-8822-45ea-aa16-911d677e303d](https://www.datosabiertos.gob.pe/dataset/personas-desaparecidas/resource/f49ae77f-8822-45ea-aa16-911d677e303d) (consultado el 26 de
727 septiembre de 2026).
- 728 [5] Defensoría del Pueblo, ¿Qué pasó con ellas?, Reporte Igualdad y No Violencia N.º 61,
729 Lima, febrero de 2025. [https://www.defensoria.gob.pe/wp-](https://www.defensoria.gob.pe/wp-content/uploads/2025/03/Reporte-Igualdad-y-No-Violencia-N-61-Qué-pasó-con-ellas-Febrero-2025.pdf)
730 [content/uploads/2025/03/Reporte-Igualdad-y-No-Violencia-N-61-Qué-pasó-con-ellas-](https://www.defensoria.gob.pe/wp-content/uploads/2025/03/Reporte-Igualdad-y-No-Violencia-N-61-Qué-pasó-con-ellas-Febrero-2025.pdf)
731 [Febrero-2025.pdf](https://www.defensoria.gob.pe/wp-content/uploads/2025/03/Reporte-Igualdad-y-No-Violencia-N-61-Qué-pasó-con-ellas-Febrero-2025.pdf)
- 732 [6] K. Janowicz, S. Gao, G. McKenzie, Y. Hu, B. Bhaduri, GeoAI: spatially explicit
733 artificial intelligence techniques for geographic knowledge discovery and beyond, Int. J.
734 Geogr. Inf. Sci. 34 (2020) 625–636. <https://doi.org/10.1080/13658816.2019.1684500>

735 [7] L. Anselin, Local indicators of spatial association—LISA, *Geogr. Anal.* 27 (1995) 93–
736 115. <https://doi.org/10.1111/j.1538-4632.1995.tb00338.x>

737 [8] A. Getis, J.K. Ord, The analysis of spatial association by use of distance statistics,
738 *Geogr. Anal.* 24 (1992) 189–206. <https://doi.org/10.1111/j.1538-4632.1992.tb00261.x>

739 [9] J.K. Ord, A. Getis, Local spatial autocorrelation statistics: distributional issues and an
740 application, *Geogr. Anal.* 27 (1995) 286–306. [https://doi.org/10.1111/j.1538-](https://doi.org/10.1111/j.1538-4632.1995.tb00912.x)
741 [4632.1995.tb00912.x](https://doi.org/10.1111/j.1538-4632.1995.tb00912.x)

742 [10] J. Ruiz Reyes, D. Congram, R.A. Sirbu, L. Floridi, Where are they? A review of
743 statistical techniques and data analysis to support the search for missing persons and the
744 new field of data-based disappearance analysis, *Forensic Sci. Int.* 376 (2025) 112582.
745 <https://doi.org/10.1016/j.forsciint.2025.112582>

746 [11] M.A. Escobar, G. Reyes-Guzman, A. Sanchez Ruiz, A municipality-level, monthly
747 dataset of disappearance cases and outcomes in Mexico from the National Registry of
748 Disappeared Persons, 2015–2025, *Data Brief* 66 (2026) 112897.
749 <https://doi.org/10.1016/j.dib.2026.112897>

750 [12] S. Openshaw, *The Modifiable Areal Unit Problem, Concepts and Techniques in Modern*
751 *Geography* 38, Geo Books, Norwich, 1984.

752 [13] A. Gelman, E. Loken, The statistical crisis in science, *Am. Sci.* 102 (2014) 460–465.
753 <https://doi.org/10.1511/2014.111.460>

754 [14] N. Breznau et al., Observing many researchers using the same data and hypothesis
755 reveals a hidden universe of uncertainty, *Proc. Natl. Acad. Sci. U.S.A.* 119 (2022)
756 e2203150119. <https://doi.org/10.1073/pnas.2203150119>

757 [15] T. VoPham, J.E. Hart, F. Laden, Y.-Y. Chiang, Emerging trends in geospatial artificial
758 intelligence (geoAI): potential applications for environmental epidemiology, *Environ.*
759 *Health* 17 (2018) 40. <https://doi.org/10.1186/s12940-018-0386-x>

- 760 [16] W. Li, S. Arundel, S. Gao, M. Goodchild, Y. Hu, S. Wang, A. Zipf, GeoAI for science
761 and the science of GeoAI, *J. Spat. Inf. Sci.* 29 (2024) 1–17.
762 <https://doi.org/10.5311/JOSIS.2024.29.349>
- 763 [17] L.J. Johnson, G.A. Listi, T.V. Wilson, M. Leitner, A spatial clustering analysis of
764 missing persons data to generate spatially informed community outreach event
765 locations, in: M. Leitner (Ed.), *New Research in Crime Modeling and Mapping Using
766 Geospatial Technologies, Geotechnologies and the Environment*, vol. 27, Springer,
767 Cham, 2025, pp. 309–327. https://doi.org/10.1007/978-3-031-81580-5_14
- 768 [18] R.M. Assunção, E.A. Reis, A new proposal to adjust Moran's I for population density,
769 *Stat. Med.* 18 (1999) 2147–2162. [https://doi.org/10.1002/\(SICI\)1097-
770 0258\(19990830\)18:16<2147::AID-SIM179>3.0.CO;2-I](https://doi.org/10.1002/(SICI)1097-0258(19990830)18:16<2147::AID-SIM179>3.0.CO;2-I)
- 771 [19] P.A.P. Moran, Notes on continuous stochastic phenomena, *Biometrika* 37 (1950) 17–
772 23. <https://doi.org/10.1093/biomet/37.1-2.17>
- 773 [20] Y. Benjamini, Y. Hochberg, Controlling the false discovery rate: a practical and
774 powerful approach to multiple testing, *J. R. Stat. Soc. Ser. B Methodol.* 57 (1995) 289–
775 300. <https://doi.org/10.1111/j.2517-6161.1995.tb02031.x>
- 776 [21] P.J. Rousseeuw, Silhouettes: a graphical aid to the interpretation and validation of
777 cluster analysis, *J. Comput. Appl. Math.* 20 (1987) 53–65. [https://doi.org/10.1016/0377-
778 0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)
- 779 [22] L. Kaufman, P.J. Rousseeuw, *Finding Groups in Data: An Introduction to Cluster
780 Analysis*, Wiley, New York, 1990. <https://doi.org/10.1002/9780470316801>
- 781 [23] R. Tibshirani, G. Walther, T. Hastie, Estimating the number of clusters in a data set via
782 the gap statistic, *J. R. Stat. Soc. Ser. B Stat. Methodol.* 63 (2001) 411–423.
783 <https://doi.org/10.1111/1467-9868.00293>

784 [24] T. Lange, V. Roth, M.L. Braun, J.M. Buhmann, Stability-based validation of clustering
785 solutions, *Neural Comput.* 16 (2004) 1299–1323.
786 <https://doi.org/10.1162/089976604773717621>

787 [25] C. Hennig, Cluster-wise assessment of cluster stability, *Comput. Stat. Data Anal.* 52
788 (2007) 258–271. <https://doi.org/10.1016/j.csda.2006.11.025>

789 [26] U. von Luxburg, Clustering stability: an overview, *Found. Trends Mach. Learn.* 2
790 (2010) 235–274. <https://doi.org/10.1561/22000000008>

791 [27] H.R. Künsch, The jackknife and the bootstrap for general stationary observations, *Ann.*
792 *Stat.* 17 (1989) 1217–1241. <https://doi.org/10.1214/aos/1176347265>

793 [28] S. Kaufman, S. Rosset, C. Perlich, O. Stitelman, Leakage in data mining: formulation,
794 detection, and avoidance, *ACM Trans. Knowl. Discov. Data* 6 (2012) 15.
795 <https://doi.org/10.1145/2382577.2382579>

796 [29] S. Kapoor, A. Narayanan, Leakage and the reproducibility crisis in machine-learning-
797 based science, *Patterns* 4 (2023) 100804. <https://doi.org/10.1016/j.patter.2023.100804>

798 [30] N.X. Vinh, J. Epps, J. Bailey, Information theoretic measures for clusterings
799 comparison: variants, properties, normalization and correction for chance, *J. Mach.*
800 *Learn. Res.* 11 (2010) 2837–2854. <https://jmlr.org/papers/v11/vinh10a.html>

801 [31] S. Steegen, F. Tuerlinckx, A. Gelman, W. Vanpaemel, Increasing transparency through
802 a multiverse analysis, *Perspect. Psychol. Sci.* 11 (2016) 702–712.
803 <https://doi.org/10.1177/1745691616658637>

804 [32] U. Simonsohn, J.P. Simmons, L.D. Nelson, Specification curve analysis, *Nat. Hum.*
805 *Behav.* 4 (2020) 1208–1214. <https://doi.org/10.1038/s41562-020-0912-z>

806 [33] M. James, J. Anderson, J. Putt, Missing Persons in Australia, Research and Public
807 Policy Series No. 86, Australian Institute of Criminology, Canberra, 2008.
808 <https://www.aic.gov.au/publications/rpp/rpp86>

- 809 [34] L. Ferguson, W. Picknell, Repeat or chronic?: examining police data accuracy across
810 the ‘history’ classifications of missing person cases, *Polic. Soc.* 32 (2022) 680–694.
811 <https://doi.org/10.1080/10439463.2021.1981899>
- 812 [35] [dataset] Ministerio del Interior (MININTER), Base de datos de personas desaparecidas
813 a julio 2025, Lima, 12 de septiembre de 2025.
814 [https://www.gob.pe/institucion/mininter/informes-publicaciones/7160708-base-de-](https://www.gob.pe/institucion/mininter/informes-publicaciones/7160708-base-de-datos-de-personas-desaparecidas-a-julio-2025)
815 [datos-de-personas-desaparecidas-a-julio-2025](https://www.gob.pe/institucion/mininter/informes-publicaciones/7160708-base-de-datos-de-personas-desaparecidas-a-julio-2025)
- 816 [36] [dataset] Instituto Nacional de Estadística e Informática (INEI), Perú: Población total
817 proyectada al 30 de junio de cada año, según departamento, provincia y distrito, 2018–
818 2026. [https://www.gob.pe/institucion/inei/informes-publicaciones/6894980-peru-](https://www.gob.pe/institucion/inei/informes-publicaciones/6894980-peru-poblacion-total-proyectada-al-30-de-junio-de-cada-ano-segun-departamento-provincia-y-distrito-2018-2026)
819 [poblacion-total-proyectada-al-30-de-junio-de-cada-ano-segun-departamento-provincia-](https://www.gob.pe/institucion/inei/informes-publicaciones/6894980-peru-poblacion-total-proyectada-al-30-de-junio-de-cada-ano-segun-departamento-provincia-y-distrito-2018-2026)
820 [y-distrito-2018-2026](https://www.gob.pe/institucion/inei/informes-publicaciones/6894980-peru-poblacion-total-proyectada-al-30-de-junio-de-cada-ano-segun-departamento-provincia-y-distrito-2018-2026) (consultado el 26 de septiembre de 2026).
- 821 [37] Defensoría del Pueblo, Defensoría del Pueblo: en enero se produjeron 671 denuncias
822 por desaparición de mujeres y 16 feminicidios, nota de prensa, Lima, 16 de febrero de
823 2023. [https://www.defensoria.gob.pe/defensoria-del-pueblo-en-enero-se-produjeron-](https://www.defensoria.gob.pe/defensoria-del-pueblo-en-enero-se-produjeron-671-denuncias-por-desaparicion-de-mujeres-y-16-feminicidios/)
824 [671-denuncias-por-desaparicion-de-mujeres-y-16-feminicidios/](https://www.defensoria.gob.pe/defensoria-del-pueblo-en-enero-se-produjeron-671-denuncias-por-desaparicion-de-mujeres-y-16-feminicidios/)
- 825 [38] [dataset] J.E. Sanchez Rosas, peru-geojson: archivos GeoJSON con los polígonos de
826 departamentos, provincias y distritos del Perú, repositorio GitHub, licencia MPL-2.0.
827 <https://github.com/juaneladio/peru-geojson> (consultado el 26 de septiembre de 2026).
- 828 [39] B. Efron, Bootstrap methods: another look at the jackknife, *Ann. Stat.* 7 (1979) 1–26.
829 <https://doi.org/10.1214/aos/1176344552>
- 830 [40] F. Pedregosa et al., Scikit-learn: machine learning in Python, *J. Mach. Learn. Res.* 12
831 (2011) 2825–2830. <https://jmlr.org/papers/v12/pedregosa11a.html>
- 832 [41] R.J.G.B. Campello, D. Moulavi, J. Sander, Density-based clustering based on
833 hierarchical density estimates, in: *Advances in Knowledge Discovery and Data Mining*

834 (PAKDD 2013), Lect. Notes Comput. Sci. 7819, Springer, Berlin, 2013, pp. 160–172.
835 https://doi.org/10.1007/978-3-642-37456-2_14
836 [42] L. Hubert, P. Arabie, Comparing partitions, J. Classif. 2 (1985) 193–218.
837 <https://doi.org/10.1007/BF01908075>
838 [43] D.L. Davies, D.W. Bouldin, A cluster separation measure, IEEE Trans. Pattern Anal.
839 Mach. Intell. PAMI-1 (1979) 224–227. <https://doi.org/10.1109/TPAMI.1979.4766909>
840 [44] T. Caliński, J. Harabasz, A dendrite method for cluster analysis, Commun. Stat. 3
841 (1974) 1–27. <https://doi.org/10.1080/03610927408827101>
842 [45] S.J. Rey, L. Anselin, PySAL: a Python library of spatial analytical methods, Rev. Reg.
843 Stud. 37 (2007) 5–27. <https://doi.org/10.52324/001c.8285>
844 [46] Y. Benjamini, D. Yekutieli, The control of the false discovery rate in multiple testing
845 under dependency, Ann. Stat. 29 (2001) 1165–1188.
846 <https://doi.org/10.1214/aos/1013699998>
847 [47] J. Lin, Divergence measures based on the Shannon entropy, IEEE Trans. Inf. Theory 37
848 (1991) 145–151. <https://doi.org/10.1109/18.61115>
849 [48] D.M. Endres, J.E. Schindelin, A new metric for probability distributions, IEEE Trans.
850 Inf. Theory 49 (2003) 1858–1860. <https://doi.org/10.1109/TIT.2003.813506>
851 [49] [dataset] M. Evangelista Gamarra, E.A. Alama Carreño, P.E. Figueroa Rosas, Datos y
852 código para «Un marco GeoAI reproducible para el análisis espaciotemporal explicable
853 de registros nacionales de personas desaparecidas», versión 3.3.2, Zenodo, 2026.
854 [\[https://doi.org/10.5281/zenodo.XXXXXXX\]](https://doi.org/10.5281/zenodo.XXXXXXX)